PART II-03
머신러닝 기본

시간계획

- 오늘도 파이팅 입니다.^^

시간	학습내용
09:00~10:00	회귀모델 이해 및 성능 최적화를 위한 feature engineering 이해
10:20~11:20	LinearRegression(단순선형회귀) 실습
11:40~12:40	회귀모델 데이터 학습 및 예측
12:40~14:00	즐거운 점심 시간
14:00~15:00	앙상블 이해 및 알고리즘 살펴보기
15:20~16:20	랜덤포래스트 실습
16:40~17:50	XGBoost 실습

지도학습(Supervised Learning)
앙상블 학습모델(Ensemble Learning Model)

학습목표

- 앙상블 학습의 부스팅과 배깅을 이해한다.
- 랜덤 포래스트 알고리즘을 활용해 머신러닝 모델을 만든다.
- XGBoost 알고리즘을 이해하고, 머신러닝 모델을 만든다.
- 결측치를 확인하고, 중위값, 최빈값으로 채운다.
- 여러 학습모델의 성능을 비교 평가한다.

앙상블 학습 개요

- **여러 개의 분류기(Classifier)를 생성**하고 그 예측을 결합함으로써 보다 정확한 최종 예측을 도출하는 기법

- 어려운 문제의 결론을 내기 위해 여러 명의 전문가로 위원회를 구성해 다양한 의견을 수렴하고 결정하는 것과 비슷

- 앙상블 학습의 목표는 **다양한 분류기의 예측 결과를 결합함으로써 단일 분류기보다 신뢰성이 높은 예측 값을 얻음**.

앙상블의 유형

- 보팅(Voting)
- **배깅**(Bagging)
  - 랜덤 포레스트(Random forest) 알고리즘
- **부스팅**
  - 에이다 부스팅, 그래디언트 부스팅, **XGBoost,** LightGBM
  - **정형 데이터의 분류나 회귀에서 GBM 부스팅 계열의 앙상블이 전반적으로 높은 예측 성능**을 나타냄
- 스태킹(Stacking)
  - 여러가지 모델을 기반으로 메타 모델을 수립함.
- 넓은 의미로 서로 다른 모델을 결합한 것들을 앙상블로 지칭하기도 함

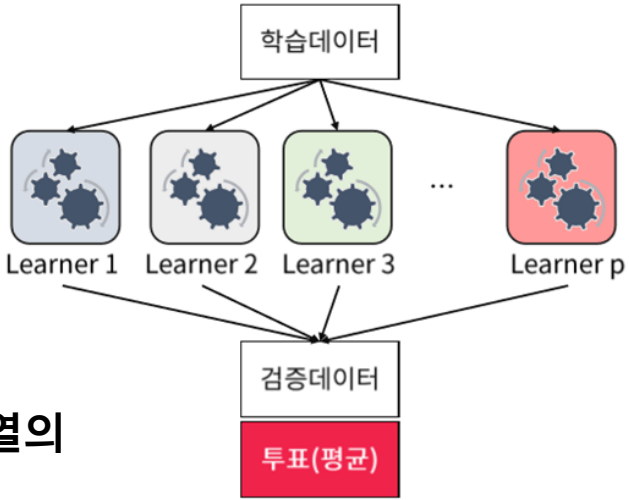

앙상블의 특징

- 단일 모델의 약점을 다수의 모델을 결합하여 보완
- 뛰어난 성능을 가진 모델들로 만 구성하는 것보다 성능이 떨어지더라도 서로 다른 유형의 모델을 섞는 것이 오히려 전체 성능에 도움이 될 수 있음.
- 랜덤 포레스트 및 **뛰어난 부스팅 알고리즘들은 모두 결정 트리 알고리즘을 기반 알고리즘을 적용**함.
- 결정 트리의 단점인 **과적합**(오버 피팅)을 수십~수천개의 많은 분류기를 결합해 **보완**하고 장점인 **직관적인 분류 기준은 강화**함.

보팅(Voting)과 배깅(Bagging)

보팅(Voting) 방식

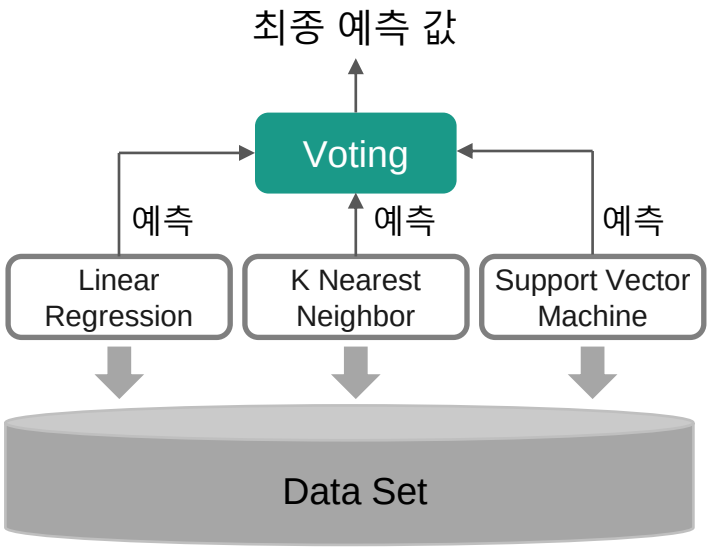

보팅은 **서로 다른 분류 알고리즘**이 **같은 데이터 세트를 학습**하고 예측한 결과를 보팅을 통해 최종 예측결과를 선정함

배깅(Bagging) 방식

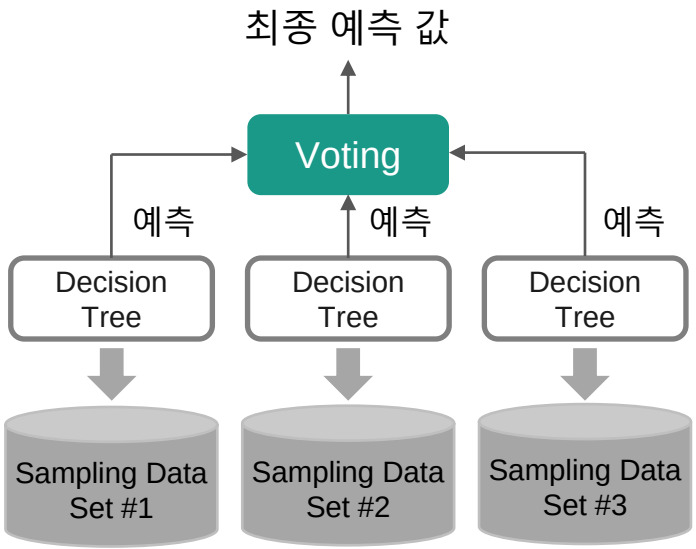

배깅은 각각의 **분류기가 모두 같은 유형**의 알고리즘 기반이지만, **데이터 샘플링을 서로 다르게** 학습 수행하여 보팅 수행

앙상블 학습(Ensemble Learning)
랜덤 포레스트(Random forest)

앙상블 학습 - 배깅(Bagging)

보팅(Voting) 방식

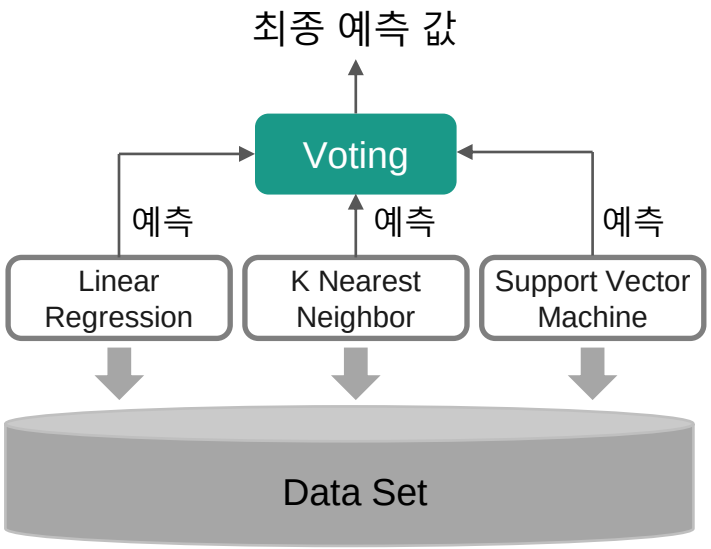

보팅은 **서로 다른 분류 알고리즘**이 **같은 데이터 세트를 학습**하고 예측한 결과를 보팅을 통해 최종 예측결과를 선정함

배깅(Bagging) 방식

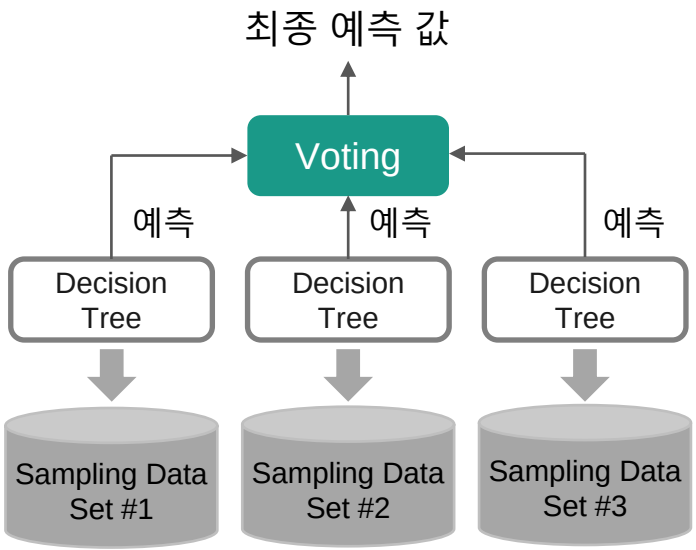

배깅은 각각의 **분류기가 모두 같은 유형**의 알고리즘 기반이지만, **데이터 샘플링을 서로 다르게** 학습 수행하여 보팅 수행

배깅 - 랜덤 포레스트(Random Forest)

- 다재 다능한 알고리즘
- 앙상블 알고리즘 중 비교적 빠른 수행 속도를 가짐
- 다양한 영역에서 높은 예측 성능을 보이고 있음.
- **여러 개의 결정 트리 분류기가 전체 데이터에서 배깅 방식으로 각자의 데이터를 샘플링해서 개별적으로 학습 후 보팅**을 통해 예측

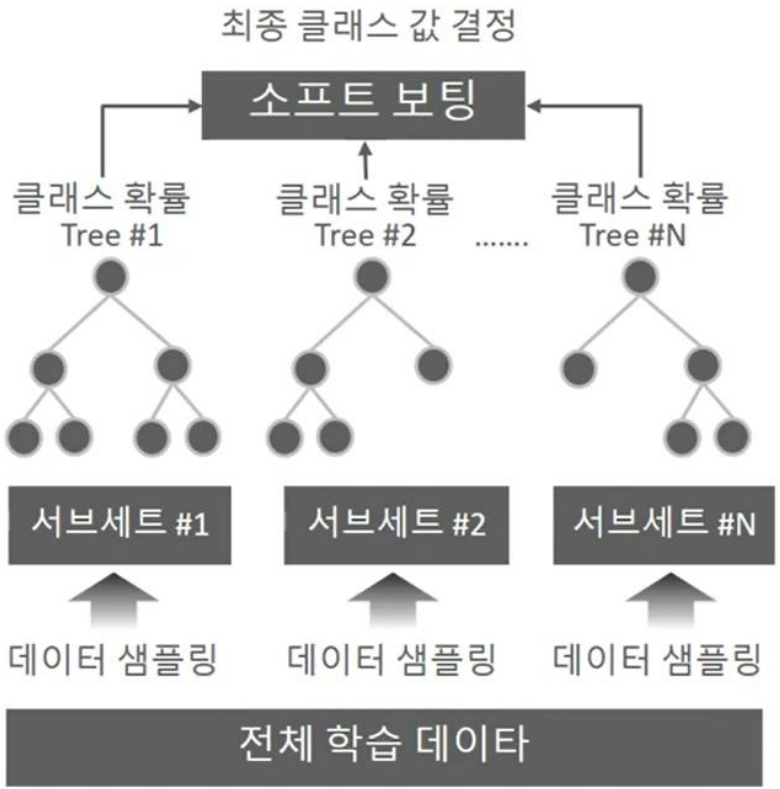

배깅 - 랜덤 포레스트(Random Forest)

- 랜덤 포레스트(Random Forest) 의 장점
  - **많은 하이퍼 파라미터 튜닝을 거치지 않아도 일반적으로 안정적으로 좋은 성능을 발휘함**
  - **병렬 처리**를 이용해서 여래개의 트리를 한번에 학습시킬 수 있음 (**n_jobs = -1**로 지정 시, 시스템의 모든 processor 사용)

- 랜덤 포레스트(Random Forest)의 단점
  - 학습시간이 상대적으로 오래 걸림

랜덤 포레스트 - 부트 스트래핑 분할

- 개별 분류기 : 결정 트리
- 개별 분류기의 학습 데이터 세트 * Bagging : bootstrap aggregating
  - 부트스트래핑(bootstrapping) 분할 방식
    : 전체 데이터에서 일부가 중첩되게 샘플링 된 데이터 세트
- 원본 데이터의 건수가 10개인 학습 데이터 세트에 랜덤 포레스트를 3개의 결정 트리기반으로 학습(n_estimators=3) 할 때의 데이터 서브 세트

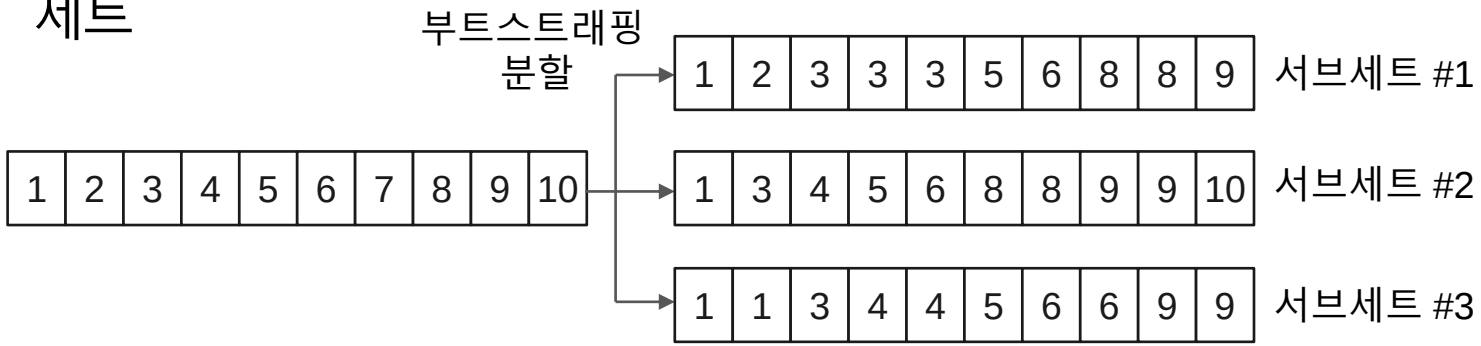

Random Forest Estimator

scikit-learning의 랜덤 포레스트 Estimator

- sklearn.ensemble.RandomForestClassifier (분류문제에서 사용)
- sklearn.ensemble.RandomForestRegressor (회귀문제에서 사용)

랜덤 포레스트 하이퍼 파라미터

RandomForestClassifier Hyper-Parameter

- n_estimators : **랜덤 포레스트에서 결정트리의 개수 지정**, 디폴트 10개 많이 설정할 수록 좋은 성능을 기대할 수 있지만, 계속 증가시킨다고 성능이 무조건 향상되는 것은 아님. 늘릴수록 학습 시간이 오래 걸림
- max_features : **결정트리의 최대 feature 수**, 디폴트는 auto(sqrt). 랜덤 포레스트의 트리를 분할 하는 피처를 참조할 때 sqrt(전체 피처 개수) 만큼 참조(전체 피처가 16개면 4개로 참조)
- max_depth, min_samples_leaf : 결정트리와 동일하게 과적합을 개선하기 위해 사용

[참고]DataFrame의 replace() 함수 복습

- DataFrame.replace()함수를 이용해서 컬럼의 값을 원하는 형태로 변경할 수 있음.

- 숫자형 값을 문자형으로, 숫자형 값을 다른 숫자로

```
# No/Yes 값을 0, 1로 변경
 df['RainToday'].replace({ 'No': 0, 'Yes': 1 }, inplace=True)
 df['RainTomorrow'].replace({ 'No': 0, 'Yes': 1 }, inplace=True)
```

https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.replace.html

원-핫 인코딩(One-Hot-Encoding)

- 범주형 값을 이진화 된 값으로 바꿔서 표현하는 것
- Label Encoding 으로
  - 개 = 1, 고양이 = 2, 토끼 = 3 이라고 했을 때,
  - 머신러닝은 1+2 = 3, 개 + 고양이 = 토끼라고 학습할 경향성을 띌 수도 있음
- 이 문제를 해결하기 위해 One-Hot-Encoding을 사용함.

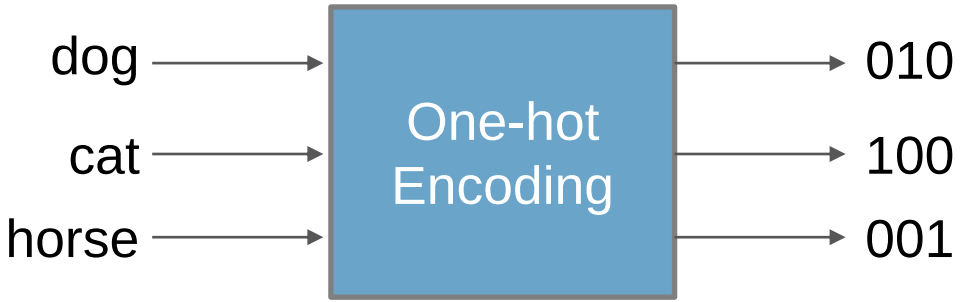

Scikit-learning OneHotEncoding

- numpy 행렬을 입력 값으로 해야함.
- 벡터 입력을 허용하지 않음. Reshape을 이용해 Matrix로 변환필요

예제 파일 참고 : one_hot_encoding_(sklearn, pandas)_ex.ipynb

```
from sklearn.preprocessing import OneHotEncoder
ohe = OneEncoder(sparse=False)
```

```
ohe_data = ohe_data.astype(int)
print(ohe_data)
```

```
[[1 0 0 0]
 [0 1 0 0]
 [1 0 0 0]
 [0 1 0 0]
 [0 0 0 1]
 [0 0 1 0]
 [0 0 1 0]]
```

sparse=False 결과

```
ohe_data = ohe_data.astype(int)
print(ohe_data)
```

```
  (0, 0)        1
  (1, 1)        1
  (2, 0)        1
  (3, 1)        1
  (4, 3)        1
  (5, 2)        1
  (6, 2)        1
```

희소행렬로 반환:
sparse=True 결과

원-핫 인코딩(One-Hot-Encoding)

- 피처 값의 유형에 따라 새로운 피처를 추가해 고유 값에 해당하는 컬럼에만 1을 표시하고 나머지 컬럼에는 0을 표시하는 방식

원본	원-핫 인코딩 – 이진코드로 범주 값을 표기함			
상품분류	상품분류_a001	상품분류_a002	상품분류_b001	상품분류_b002
a001	1	0	0	0
a002 →	0	1	0	0
a001	1	0	0	0
a002	0	1	0	0
b002	0	0	0	1
b001	0	0	1	0
b001	0	0	1	0

Pandas의 원-핫 인코딩

- get_dummies() 활용 예)

```
import pandas as pd
ohe_df = pd.get_dummies(goods)
ohe_df
```

```
goods = df['상품']
print(goods)
print(goods.shape)
```

```
0    a001
1    a002
2    a001
3    a002
4    b002
5    b001
6    b001
Name: 상품, dtype: object
(7,)
```

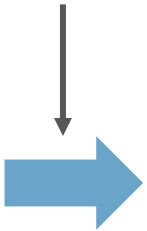

	a001	a002	b001	b002
0	1	0	0	0
1	0	1	0	0
2	1	0	0	0
3	0	1	0	0
4	0	0	0	1
5	0	0	1	0
6	0	0	1	0

[실습1] 랜덤 포레스트 – 내일 날씨 예측

Rain in Australia 데이터, 내일 날씨 예측하기

- https://www.kaggel.com/uciml/breast-ca
- 호주 기상청에서 2010년에 발표한 데이터셋
- 데이터 columns : Date, Location, RainToday, RainTomorrow…
  - 23 개 컬럼
- 데이터 개수 : 145,460

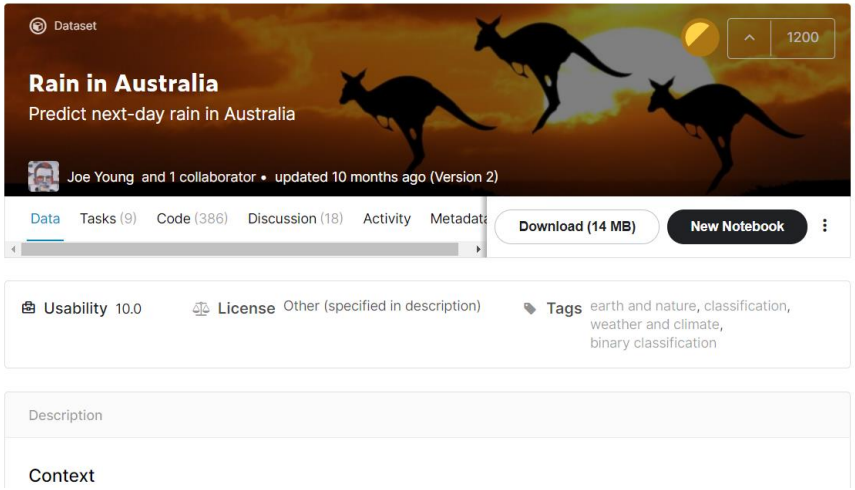

[실습1] 랜덤 포레스트 – 내일 날씨 예측

- Feature 데이터 columns : Date, Location, RainToday …
  - 22 Features (RainTomorrow 제외)
- Target Value : RainTomorrow 컬럼
  - Yes(내일 비가 옴) or No(내일 비가 오지 않음)
  - Binary Classification
- 사용 알고리즘(Estimator)
  - DecisionTreeClassifier
  - RandomforestClassifier
- 적용기법
  - Data Cleansing(결측치 처리)
  - 정확도 비교 평가

[실습1] 랜덤 포레스트 – 내일 날씨 예측

- Features

Date	: 일시
Location	: 지역
MinTemp	: 최저 기온
MaxTemp	: 최고 기온
Rainfall	: 강우량(mm)
Evaporation	: 증발량(mm)
Sunshine	: 해가 보인 시간
WindGustDir	: 자정까지 풍향
WindGustSpeed	: 자정까지 풍속
WindDir9am	: 아침풍향
WindDir3pm	: 낮풍향

WindSpeed9am	: 아침풍속
WindSpeed3pm	: 낮풍속
Humidity9am	: 아침습도
Humidity3pm	: 낮습도
Pressure9am	: 아침대기압
Pressure3pm	: 낮대기압
Cloud9am	: 아침 구름량 _x/8
Cloud3pm	: 낮 구름량 _x/8
Temp9am	: 아침 기온
Temp3pm	: 낮 기온
RainToday	: 당일강수여부
RainTomorrow	: 내일강수여부

[실습1] 랜덤 포레스트 – 내일 날씨 예측

- 결측치가 많은 데이터

내일 비가 올지 예측해보기

- 파일 : 3-5-1_ Random_Forest_내일_비가올지_예측해보기 (Rain in Australia).ipynb

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 145460 entries, 0 to 145459
Data columns (total 23 columns):
 #   Column         Non-Null Count   Dtype
---  ------         --------------   -----
 0   Date           145460 non-null  object
 1   Location       145460 non-null  object
 2   MinTemp        143975 non-null  float64
 3   MaxTemp        144199 non-null  float64
 4   Rainfall       142199 non-null  float64
 5   Evaporation    82670 non-null   float64
 6   Sunshine       75625 non-null   float64
 7   WindGustDir    135134 non-null  object
 8   WindGustSpeed  135197 non-null  float64
 9   WindDir9am     134894 non-null  object
 10  WindDir3pm     141232 non-null  object
 11  WindSpeed9am   143693 non-null  float64
 12  WindSpeed3pm   142398 non-null  float64
 13  Humidity9am    142806 non-null  float64
 14  Humidity3pm    140953 non-null  float64
 15  Pressure9am    130395 non-null  float64
 16  Pressure3pm    130432 non-null  float64
 17  Cloud9am       89572 non-null   float64
 18  Cloud3pm       86102 non-null   float64
 19  Temp9am        143693 non-null  float64
 20  Temp3pm        141851 non-null  float64
 21  RainToday      142199 non-null  object
 22  RainTomorrow   142193 non-null  object
dtypes: float64(16), object(7)
memory usage: 25.5+ MB
```

이상치(Outlier) 제거

이상치 제거(Remove Outlier)

- 이상치는 다른 데이터와 **크게 다른 값**을 갖는 데이터를 의미함
- 이상치는 오히려 **머신러닝 모델의 학습에 방해** 됨
- 이상치 제거(Remove Outlier)는 **머신러닝 모델의 성능향상에 도움**이 됨

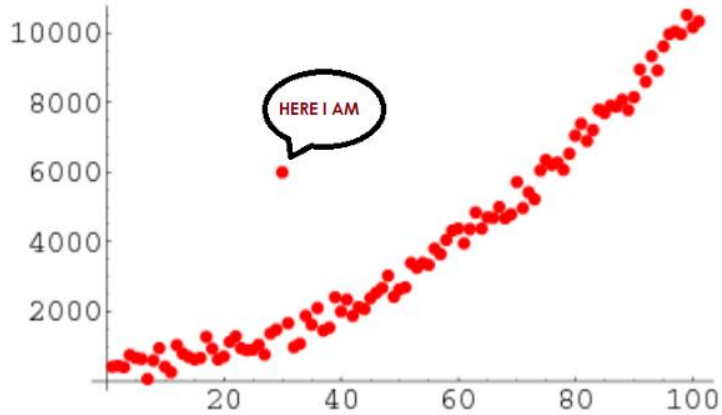

https://medium.com/analytics-vidhya/its-all-about-outliers-cbe172aa1309

이상치 제거 – IQR(Inter Quantile Range) 활용

- IQR(Inter Quantile Range) 방법을 이용해 이상치(Outiler) 제거
- 사분위 값을 이용하여 데이터의 분포 모양, 대칭성, 극단 값을 쉽게 파악할 수 있음
- seaborn의 boxplot() 활용

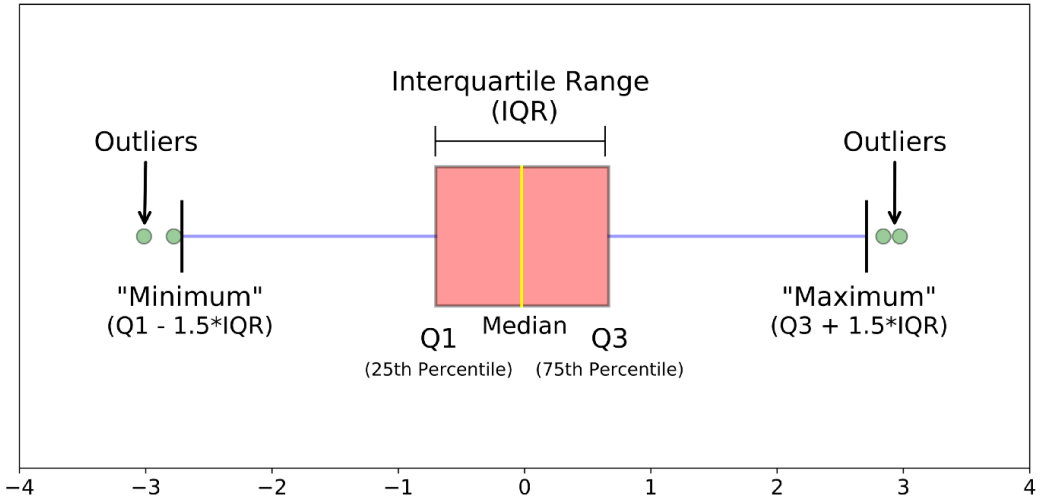

이상치 제거 – 상관분석(Correlation analysis) 활용

- 상관분석(Correlation analysis)을 활용한 이상치 제거 컬럼 선택
- target과 연관관계가 높은 feature의 이상치 제거

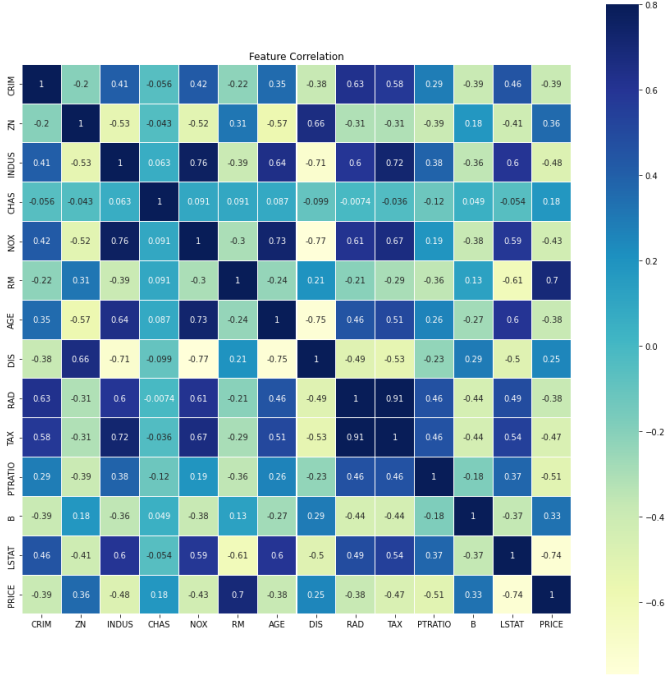

1에 가까운 값 : 두 변수들 간의 양의 상관관계가 있음.

0에 가까운 값 : 두 변수들 간의 상관관계가 없음.

-1에 가까운 값 : 두 변수들 간의 음의 상관관계가 있음.

이상치 제거 – IQR 방식 활용

- IQR 방식으로 이상치 제거 구현하기

```
def get_outlier_indices(data, columns):
    outlier_indices = []
    for column in columns:
        Q1 = data[column].quantile(0.25)
        Q3 = data[column].quantile(0.75)
        IQR = Q3 – Q1
        min_value = Q1 – 1.5*IQR
        max_value = Q3 + 1.5*IQR
        filter = ((data[column] < min_value) | (data[column] > max_value))

        outlier_data = data[column][filter]
        outliner_index = outlier_data.index
        outlier_indices.extend(outlier_index)
    return outlier_indices
```

```
print('outlier 삭제하기 전의 데이터 프레임 : ', df.shape)
delete_indices = get_outlier_indices(df, ['Humidity9am', 'Pressure9am', 'Pressure3pm', 'WindGustSpeed'])
df = df.drop(delete_indices, axis=0).reset_index(drop=True)
print('dataframe after removing outlier (etc) : ', df.shape)
```

[실습2]Outlier제거 적용 Random Forest Classifier

Rain in Australia에 이상치 제거를 적용해서 성능 향상시키기

- 데이터 : https://www.kaggel.com/uciml/breast-ca
- 호주 기상청에서 2010년에 발표한 데이터셋
- 데이터 columns : Date, Location, RainToday, RainTomorrow…
  - 23 Dimension
- 데이터 개수 : 145,460

앙상블 학습(Ensemble Learning)
XGBoost(eXtreme Gradient Boosting)

Kaggle 우승자들이 애용하는 알고리즘

XGBoost 설치(on ubuntu 18.04)

현재 실습하고 있는 가상환경에 설치하기

(MLvenv)$ pip3.8 install xgboost

Tip : lightGBM 설치

$ pip3.8 install lightgbm

XGBoost(eXtreme Gradient Boosting)

- 공식문서: https://xgboost.readthedocs.io/en/latest/index.html
- scikit-learning 외부 라이브러리
- XGBoost는 **병렬적이고, 효율적이고 최적화**된 GBM 알고리즘
- XGBoost는 **Grandient Boosting** 알고리즘에 기반함.

부스팅 – GBM(Gradient Boost Machine)

- Bagging 방식 : 매번 랜덤하게 샘플을 뽑아서 독립적으로 학습시킨 분류기들의 결과를 종합해서 앙상블 러닝 수행 - 랜덤 포레스트
- **Boosting 방식** : 매번 샘플을 뽑아서 학습시키되, **순차적으로 오차가 큰 샘플들이 뽑힐 확률이 높아지도록 가중치를 부여**하고, **다음 단계에 샘플을 뽑아서 학습시키는 알고리즘**

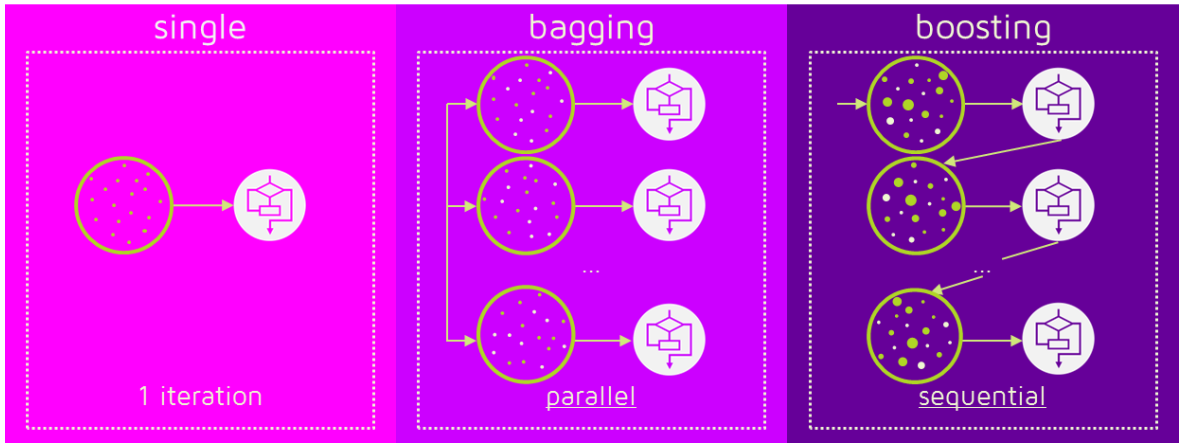

https://swalloow.github.io/bagging-boosting/

앙상블 학습 - 부스팅(Boosting)

- 여러 개의 약한 학습기(week learner)를 순차적으로 학습-예측하면서 잘못 예측한 데이터에 가중치 부여를 통해 오류를 개선해 가면서 학습하는 방식
- AdaBoost(Adaptive boosting)와 GBM(Gradient Boosting Machine), **XGBoost**, LightGBM

부스팅(Boosting) - GBM

GBM(Gradient Boosting Machine) 알고리즘

- 학습과정에서 파라미터를 최적화하는데 Gradient Descent 알고리즘 사용
- 오차가 큰 샘플들이 많이 뽑히도록 할 때 Gradient Descent 알고리즘 사용

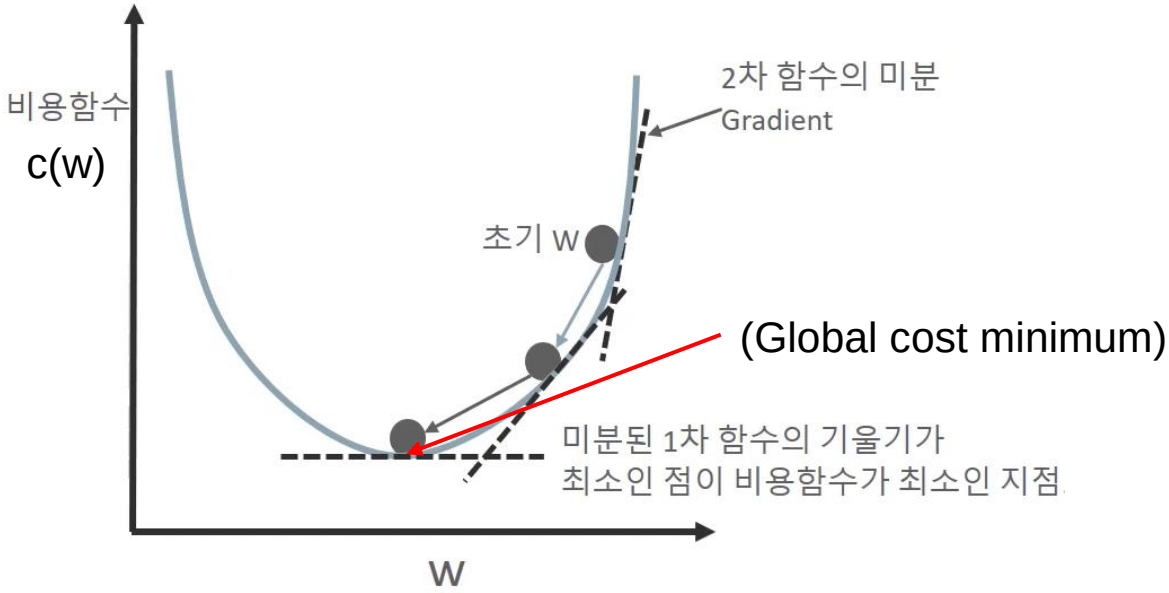

XGBoost의 장점과 단점

- XGBoost의 장점
  - 대부분의 상황에서 안정적으로 좋은 성능을 발휘함.
  - Feature Engineering을 많이 적용하지 않아도 안정적인 성능을 보여줌

- XGBoost의 단점
  - 하이퍼 파리미터가 방대해서 튜닝하는 것이 상대적으로 어려움.

[실습3]Stroke Prediction Dataset

- 데이터 : https://www.Kaggle.com/fedesoriano/stroke-prediction-dataset
- 나이, 성별, 고혈압 유무 등을 토대로 뇌졸중을 가진 사람인지 아닌지를 예측해 볼 수 있는 데이터셋
- Feature columns : id, gender, age, hypertension, … , stroke
  - 12개 컬럼
  - Target Value : stroke(뇌졸중 환자) or not stroke(뇌졸중 아님)
  - Binary classification
- 데이터 개수 : 5,110개

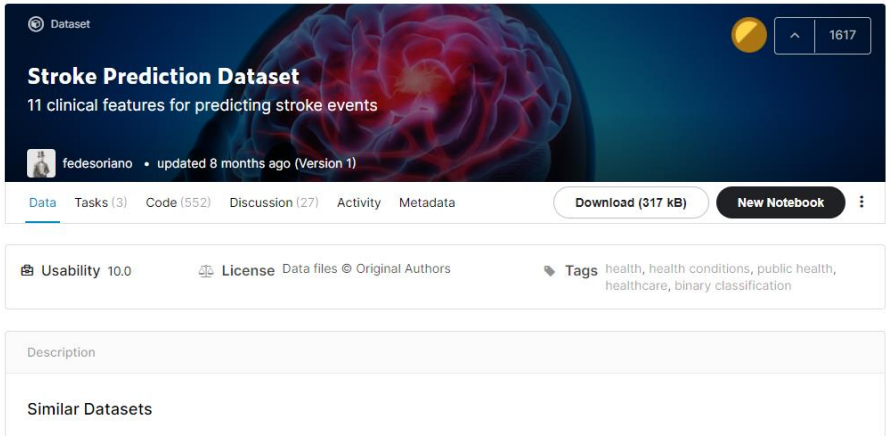

[실습3]Stroke Prediction Dataset

- 뇌졸중(腦卒中, 영어: stroke, 문화어: **뇌졸증**, 腦卒症)
- 뇌혈류 이상으로 인해 갑작스레 유발된 국소적인 신경학적 결손 증상을 통칭하는 말이다.
- **증상:** 편측 마비, 수용성언어상실증, 표현언어상...
- **다른 이름:** 뇌중풍(Cerebrovascular accident)
- **진단 방식:** 증상 및 의학 영상에 기반
- **병인:** 뇌 허혈, 두개내출혈

[실습3]Stroke Prediction Dataset 특징

- id : 구분 id
- gender : "Male", "Female", "Other"
- age : 환자의 나이
- hypertension : 고혈압 환자 1, 고혈압 환자 아니며 0
- heart_disease : 심장병 환자 1, 심장병 환자 아니면 0
- ever_married : "No", "Yes"
- work_type : "children", "Govt_jov", Never_worked", "Private" or "Self-employed"
- Residence_type : "Rural" or "Urban"
- avg_glucose_level : 평균 포도당 수치
- bmi : body mass index(체질량지수: 체중/키^2=체지방양 추정)
- smoking_status : "formerly smoked", "neversmoked", "smokeds", "unknown"
- stroke : 뇌졸중 환자 1, 뇌졸중 환자 아니면 0

[실습3]Stroke Prediction – 예측모델 셋팅

- 입력 데이터
  - id, gender, age, hypertension, …, smoking_status
  - 11 features
- Target data
  - stroke 컬럼 : 1(뇌졸중 환자), 0(뇌졸중 환자 아님)
  - binary Classification
- 사용 알고리즘(Estimator)
  - DecisionTreeClassifier
  - RandomforestClassifier
  - XGBoostClassifer
- 추가적인 적용 기법
  - Data Cleansing(결측치 처리)

[실습3]Stroke Prediction

- XGBoost 알고리즘 적용 뇌졸중 환자인지 예측해 보기

실습파일 : 3-5-3_XGBoost_stroke_patient_pred.ipynb

교재 소스

https://github.com/rickiepark/introduction_to_ml_with_python

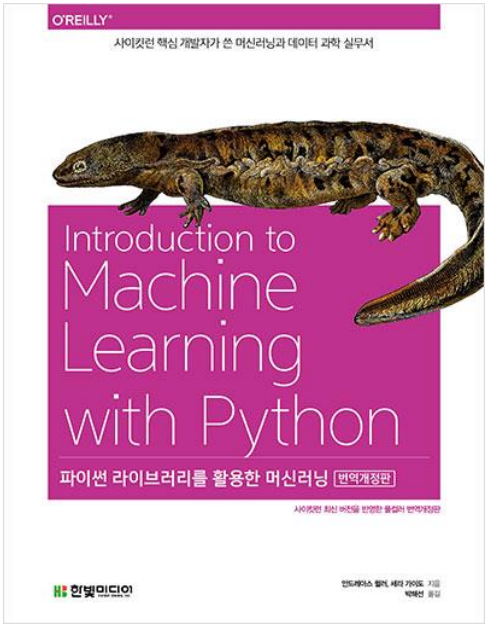

실전으로 더 깊이 공부 하고 싶다면

- 파이썬 머신러닝 완벽 가이드, 위키북스
- 핸즈온 머신러닝 – 한빛 미디어